

LLM’lerde Matematiksel Problem Çözme için Farklı LoRA İnce Ayar Yaklaşımlarının Değerlendirilmesi

Muhammet Emin AYDINALP
25501819

Özet

Bu çalışmada, bir modelin çözemediği matematik soruları için güçlü bir öğretmen modelden alınan çözümlerin, aynı yapıya sahip benzer sorulara ve bağımsız test kümesine ne ölçüde aktarılabildiğini inceledik. Çalışmada temel model olarak Qwen/Qwen3.5-4B modeli, öğretmen model olarak gpt-oss-120b, veri kümesi olarak ise GSM8K_TR kullanıldı. Temel modelin veri kümesinde çözemediği soruların çözümlerini öğretmen modelden alarak bir eğitim kümesi oluşturduk. Ayrıca aynı öğretmen modelden bu sorulara benzer yeni sorular üretmesini istedik. Modeli her bir soru-cevap çiftiyle LoRA kullanarak ince ayar yaptık ve ince ayar yapılan sorunun benzeriyle test ederek iki farklı stratejiyle ilerledik. Birinci strateji olan Selective, benzer soru çözülebilirse mevcut adapter’ı güncelledi, çözülemediyse güncellemedi. İkinci strateji olan Blind ise her durumda adapter’ı güncelledi. Son aşamada, bu eğitim kümesinden tamamen bağımsız farklı bir test kümesinde iki ayrı stratejiyle eğitilmiş modelleri karşılaştırdık. Benzer soru değerlendirmesinde Selective strateji %81,0 doğruluk, Blind strateji ise %77,8 doğruluk sağladı. Ancak bağımsız test kümesinde temel modelin doğruluğu %58,0 iken, Selective stratejinin doğruluğu %54,8, Blind stratejinin doğruluğu ise %59,2 olarak ölçüldü. Bu durum, öğretmen çözümüyle yapılan tek örneklik eğitimin benzer sorulara aktarım sağlayabildiğini, ancak genel test başarısını garanti etmediğini göstermektedir.

Anahtar Kelimeler: Büyük dil modelleri, matematiksel akıl yürütme, GSM8K_TR, LoRA, fine-tuning

1 Giriş

Matematiksel sözel problem çözme, büyük dil modellerinin (LLM) akıl yürütme yeteneklerini değerlendirmek için sık kullanılan görevlerden biridir [1]. Bu görevlerde modelin yalnızca doğru bilgiyi hatırlaması yeterli değildir [2]. Problemdaki nicelikleri ayırt etmesi, ilişkileri kurması, ara hesaplamaları doğru sırayla yapması ve en sonunda tek bir sayısal cevap üretmesi gerekir. GSM8K veri kümesi, bu tür çok adımlı ilkökul düzeyi matematik problemlerini değerlendirmek için yaygın olarak kullanılmaktadır [3]. Cobbe ve arkadaşları, GSM8K üzerinde büyük modellerin bile güvenilir sonuçlar vermekte zorlandığını ve çözüm doğrulama yaklaşımlarının performansı artırabildiğini göstermiştir [4].

LLM’lerde matematiksel akıl yürütmeyi geliştirmek için önerilen yaklaşımlardan biri, modeli belirli veri veya görevler üzerinde yeniden eğitmektir [5]. Büyük model-

lerin tüm parametrelerini güncellemek çoğu zaman pahalı olduğundan, parametre verimli fine-tuning yöntemleri öne çıkmıştır [6]. LoRA, temel model ağırlıklarını sabit tutup düşük dereceli eğitilebilir matrisler ekleyerek bu maliyeti azaltır [7]. Bu sayede modelin davranışı küçük adapter ağırlıkları üzerinden değiştirilebilir. Bizim çalışmamızda da her güncelleme LoRA adapter üzerinden yapılmıştır.

Bu çalışma, klasik fine-tuning sorusundan biraz farklı bir noktaya odaklanır. İki araştırma sorumuz var. Birinci soru, bir modelin yanlış çözdüğü bir sorunun öğretmen çözümünü öğrenmesinin, aynı matematiksel yapıya sahip benzer bir soruyu çözmesini sağlayıp sağlamadığıdır. İkinci soru, benzer sorularda kazanılan başarının final test kümesinde nasıl bir fark oluşturacağıdır. Bu sorular sürekli öğrenme ve unutma problemleriyle de ilişkilidir. Ardışık öğrenme sırasında yeni örneklerden gelen güncellemeler modelin daha önce doğru yaptığı örnekleri bozabilir. Bu durum literatürde catastrophic forgetting olarak tartışılmıştır [8]. Sürekli öğrenme çalışmaları, yeni bilgiyi öğrenirken önceki bilgiyi korumanın temel bir zorluk olduğunu vurgular [9].

Bu bağlamda iki stratejiyi karşılaştırdık. İlk strateji olan Selective, her yeni çözümü öğrendikten sonra yalnızca eşleşen benzer soru doğru çözüldüyse güncellemeyi kabul eder. İkinci strateji olan Blind, aynı güncellemeleri herhangi bir geri alma yapmadan sırayla biriktirir. Beklenti, Selective stratejinin zararlı güncellemeleri ele-yerek daha güvenli bir öğrenme yolu sağlamasıydı. Deney sonucunda bunun yalnızca benzer soru başarısı için geçerli olduğu, bağımsız test kümesinde ise Blind stratejinin daha iyi genellediği görüldü.

2 Yöntem

2.1 Veri seti

Deneylerde GSM8K_TR veri kümesi kullanıldı. Bu veri kümesi, GSM8K biçimindeki matematiksel sözel problemlerin Türkçe örneklerini içerir ve Hugging Face üzerinde `ytu-ce-cosmos/gsm8k_tr` adıyla yayımlanmıştır [10]. Veri kümesindeki her örnek bir soru metni ve çözüm metni içerir. Çalışmada değerlendirme ölçütü tek bir sayısal son cevap üzerinden kurulduğu için final cevabı saat biçiminde olan örnekler deney kapsamına dahil edilmedi.

Sabit test kümesi genel popülasyondan rastgele seçilen 500 sorudan oluşturuldu. Eğitim kümesi ise temel modelin yanlış cevapladığı ve öğretmen model yardımıyla doğrulanan örneklerden rastgele seçilen 500 sorudan oluştu-

ruldu. Eğitim ve test kümeleri arasında çakışma olmadığı doğrulandı.

2.2 Temel model ve değerlendirme

Temel model olarak Qwen/Qwen3.5-4B (M1) kullanıldı [11]. M1, GSM8K_TR üzerinde Türkçe bir çözüm promptu ile çalıştırıldı. Aynı prompt şablonu M1, Selective ve Blind final test değerlendirmelerinde kullanıldı. Değerlendirmede kullanılan prompt Prompt 1’de verilmiştir. Şablondaki {question} alanı ilgili soru metniyle değiştirildi.

Prompt 1: Değerlendirmede kullanılan Türkçe çözüm promptu.

Soru:
{question}

Bu problemi kısaca açıklayarak Türkçe çöz.
Gereksiz açıklama yapma, 2-5 kısa hesap adımı yaz.
Cevabının son satırında yalnızca şu formatı kullan:
Final cevap: <sayı>

Üretim sürecinde örnekleme kullanılmadı ve model çıktıları deterministik biçimde alındı (do_sample=False). Değerlendirmelerde giriş dizisi en fazla 1024 token, üretilen yanıt ise en fazla 256 yeni token ile sınırlandırıldı.

Model çıktılarından final sayısal cevap düzenli ifadeler ve sayısal normalleştirme fonksiyonları ile çıkarıldı. Virgül, nokta, kesir ve basit biçim farklılıkları normalize edildi. Tahmin edilen sayı ile referans sayı Decimal tabanlı sayısal karşılaştırmaya tabi tutuldu ve aralarındaki fark 10^{-6} veya daha küçük olduğunda cevap doğru kabul edildi.

2.3 Başarısız örneklerin belirlenmesi

M1 modeli veri kümesi üzerinde değerlendirildiğinde 8768 örnekten 4683 tanesi doğru, 4085 tanesi yanlış olarak işaretlendi. Yanlış işaretlenen örneklerin tamamının gerçekten öğretilabilir hata olup olmadığını kontrol etmek için öğretmen model olarak openai/gpt-oss-120b:free kullanıldı. Öğretmen modelin referans cevapla uyduğu ve M1 cevabından ayrıştığı örnekler doğrulanmış başarısız örnek kabul edildi. Bu süreç sonunda 2578 doğrulanmış başarısız örnek elde edildi. Bu örneklerden test kümesiyle çakışmayan 500 örnek nihai eğitim kümesi olarak seçildi.

2.4 Benzer soru ve öğretmen çözümü üretimi

Her eğitim sorusu için öğretmen modelden aynı matematiksel yapıyı koruyan yeni bir Türkçe benzer soru üretmesi istendi. Bu benzer soruların orijinal soruyla bire bir aynı olmaması, final cevabının orijinal final cevapla aynı olmaması, saat biçiminde cevap içermemesi ve sayısal referansının ayrıştırılabilir olması otomatik olarak kontrol edildi. Sonuç olarak 500 geçerli benzer soru elde edildi.

Ayrıca her eğitim sorusu için öğretmen modelden çözüm metni alındı. Bu çözüm metinleri LoRA fine-tuning sırasında hedef çıktı olarak kullanıldı. Böylece

her adımda üçlü bir yapı oluştu. Bunlar M1’in yanlış yaptığı asıl soru, öğretmen çözümü ve bu soruya karşılık gelen benzer soru şeklindedir.

2.5 Fine-tuning stratejileri

Fine-tuning LoRA adapter üzerinden yapıldı. Temel modelin ana ağırlıkları güncellenmedi ve yalnızca adapter parametreleri eğitildi. Selective ve Blind stratejilerinde aynı LoRA ayarları kullanıldı. Deneylerde kullanılan temel fine-tuning ayarları Tablo 1’de verilmiştir.

Tablo 1: Fine-tuning sırasında kullanılan LoRA ve eğitim ayarları.

Ayar	Değer
LoRA r	16
LoRA alpha	32
LoRA dropout	0.05
Epoch sayısı	3
Öğrenme oranı	2×10^{-4}
Maksimum eğitim uzunluğu	1536 token
Maksimum giriş uzunluğu	1024 token
Maksimum yeni token sayısı	256
Seed	42
Hedef modüller	q_proj, k_proj, v_proj, o_proj, gate_proj, up_proj, down_proj

Selective stratejide aktif adapter başlangıçta temel model üzerindeki boş veya başlangıç LoRA durumudur. Her adımda aktif adapter, ilgili eğitim sorusu ve öğretmen çözümü ile eğitilerek geçici bir aday adapter oluşturuldu. Aday adapter, eşleşen benzer soru üzerinde değerlendirildi. Eğer benzer sorunun final cevabı doğruysa aday adapter aktif adapter olarak kabul edildi. Yanlışsa aday adapter geri alındı ve önceki aktif adapter korundu.

Blind strateji aynı soru sırasını, aynı öğretmen çözümlerini ve aynı hiperparametreleri kullandı. Fark, her güncellenmenin tutulmasıdır. Benzer soru sonucu yine kaydedildi, fakat yanlış olsa bile adapter geri alınmadı.

2.6 Final test değerlendirmesi

Eğitim tamamlandıktan sonra M1 temel model, Selective döngü sonunda elde edilen final adapter ve Blind döngü sonunda elde edilen final adapter aynı 500 soruluk test kümesinde değerlendirildi. Selective ve Blind modelleri, temel Qwen/Qwen3.5-4B modeli üzerine ilgili active_adapter yüklenerek çalıştırıldı.

3 Bulgular


3.1 Benzer soru başarısı

Selective strateji 500 fine-tuning adımının 405 tanesinde benzer soruyu doğru çözdü ve bu güncellemeleri kabul etti. 95 adımda benzer soru yanlış çözüldüğü için güncelleme geri alındı. Blind strateji tüm 500 güncellemeyi tuttu, fakat benzer soru değerlendirmesinde 389 doğru ve 111 yanlış elde etti. Bu sonuçlar Tablo 2’de verilmiştir.

Tablo 2: Selective ve Blind stratejilerinin performansı.

Strateji	Adım	Doğruluk Oranı	Doğruluk	Kabul
Selective	500	405 / 500	0.810	405
Blind	500	389 / 500	0.778	500

Benzer soru adımlarında iki stratejinin örtüşme yapısı da incelendi. 359 örnekte iki strateji de doğru cevap verdi. 46 örnekte yalnızca Selective doğruydü. 30 örnekte yalnızca Blind doğruydü. 65 örnekte iki strateji de yanlış cevap verdi. Bu tablo, Selective stratejinin yerel benzer soru ölçütünde daha iyi olduğunu, ancak Blind stratejinin de bazı adımlarda Selective stratejiden ayrılarak doğru sonuca ulaştığını göstermektedir. Benzer soru değerlendirmesinde kümülatif doğruluk eğrisi Şekil 1’de verilmiştir.




Şekil 1: Kümülatif doğruluk eğrisi.

3.2 Final test başarısı

Final test sonuçları Tablo 3’de gösterilmiştir. M1 baseline 500 test sorusunun 290 tanesini doğru çözerek 0.580 doğruluk elde etti. Selective final adapter 274 doğru cevapla 0.548 doğrulukta kaldı. Blind final adapter ise 296 doğru cevapla 0.592 doğruluğa ulaştı. Modellerin final test doğrulukları Şekil 2’de gösterilmiştir.

Tablo 3: Sabit test kümesinde model başarıları.

Model	Doğruluk Oranı	Doğruluk
M1 baseline	290 / 500	0.580
Selective	274 / 500	0.548
Blind	296 / 500	0.592



Şekil 2: Final test doğruluğu.

Bu sonuç, benzer soru başarısındaki sıralamanın final test kümesine aynı şekilde taşınmadığını göstermektedir.


Tablo 4: Final testte M1’e göre düzeltme ve bozma dengesi.

Model	Düzeltilen	Bozuldu	Korundu	Net
Selective	79	95	195	-16
Blind	85	79	211	+6

Selective strateji benzer soru değerlendirmesinde daha iyi olmasına rağmen final testte baseline’in altında kalmıştır. Blind strateji ise benzer soru değerlendirmesinde daha düşük görünmesine rağmen final testte en yüksek doğruluğu vermiştir.

3.3 Düzeltme ve bozma dengesi

Final test kümesinde M1’in yanlış yaptığı 210 soru ayrı olarak incelendi. Selective strateji bu 210 sorunun 79 tanesini doğru çözdü. Blind strateji ise 85 tanesini doğru çözdü. Ancak her iki strateji de M1’in önceden doğru çözdüğü bazı soruları bozdu. Selective, M1’in doğru yaptığı 95 soruyu, Blind ise 79 soruyu yanlış yaptı. Düzeltme ve bozma dengesi Tablo 4’de, bu dengenin görsel karşılaştırması ise Şekil 3’de verilmiştir.



Şekil 3: Test setinde M1’e göre düzeltilen ve bozulan örnek sayıları.

Bu analiz, Selective stratejinin final testte neden gerilediğini açıkça göstermektedir. Selective 79 eski hatayı düzeltilmiş, fakat 95 eski doğru cevabı bozmuştur. Blind ise 85 eski hatayı düzeltilmiş ve 79 eski doğru cevabı bozmuştur. Bu nedenle Blind stratejinin net etkisi +6, Selective stratejinin net etkisi -16 olmuştur.

4 Tartışma

Her iki stratejide de benzer sorular üzerinde yapılan ölçüm sonucu yüksek skorların elde edilmiş olması, modellerin matematiksel problem çözmede ince ayar yapıldıktan sonra belirli sorularda iyileşmenin olabileceğini göstermiştir. Özellikle Selective strateji, her güncellemeyi eşleşen benzer soru üzerinde sıradığı için benzer sorulara daha çok odaklanmaktadır. Nitekim benzer soru değerlendirmesinde 0.810 doğruluk elde etmiş ve Blind stratejinin 0.778 doğruluğunu geçmiştir. Ek açıklamada verilen oy dağılımı örneği de bu yerel aktarımın somut bir karşılığını göstermektedir.

Benzer sorular üzerinde yapılan değerlendirme sonuçları ile bağımsız test başarısı ise paralellik göstermemektedir. Final testte Selective strateji 0.548 doğrulukla te-

mel modelin altına düşmüştür. Bu durum, benzer sorulardaki başarıyı referans olarak güncelleme yapmanın genellemeyi düşürebileceğini göstermektedir. Diğer taraftan bir güncelleme, hemen ardından gelen benzer soruda başarısız görünse bile daha sonraki örneklerde veya genel test dağılımında faydalı olabilir. Blind stratejinin final testte daha iyi sonuç vermesi bu yorumu destekler. Bu bulgu, Blind güncellemenin genel olarak güçlü bir çözüm olduğunu değil, bu deney koşullarında Selective kabul kuralından daha iyi genellediğini göstermektedir. Ayrıca Blind stratejisinde model her durumda güncelleme aldığı için aslında bu stratejide daha fazla örnek ile eğitim yapılmış oluyor. Blind stratejisinin test verisinde daha iyi sonuç vermesi buna da bağlı olabilir. İnce ayar sonrası her iki strateji ile elde edilen model de M1'in bazı hatalarını düzeltmiş, fakat bazı eski doğruları da bozmuştur. Bu davranış, modelin yeni örneklerden öğrenirken daha önce doğru yaptığı bazı örneklerde performans kaybedebildiğini gösteren katastrofik unutma olgusuyla uyumludur [8, 9].

Çalışmanın sınırlılığı, değerlendirmenin yalnızca final sayısal cevaba dayanmasıdır. Bu seçim matematiksel doğruluğu otomatik ölçmeyi kolaylaştırır, fakat çözüm metnindeki muhakeme kalitesini tam olarak değerlendirmez. Model doğru final sayıya hatalı ara adımlarla ulaşabilir ya da doğru muhakeme yapıp son final sayısını bulmada hata yapabilir. Bu nedenle ileride hem sayısal cevap hem de çözüm adımlarının tutarlılığını birlikte ölçen bir değerlendirme tasarımı daha zengin sonuçlar verebilir.

5 Sonuç

Bu çalışmada, GSM8K_TR üzerinde öğretmen model çözümleriyle yapılan tek örneklik LoRA güncellemelelerinin benzer sorulara ve bağımsız test kümesine etkisi incelendi. Deneyler, öğretmen çözümünün yerel benzer soru aktarımı için güçlü bir sinyal sağlayabildiğini gösterdi. Selective strateji 500 benzer sorunun 405 tanesini doğru çözerek bu ara ölçütte en iyi sonucu verdi.

Ancak final test sonuçları farklı bir tablo ortaya koydu. Blind strateji 296/500 doğru cevapla en iyi final test doğruluğunu elde etti. M1 baseline 290/500, Selective strateji ise 274/500 doğru cevapta kaldı. Bu sonuç, tek benzer soru üzerinden verilen seçici kabul kararının genel test başarısını garanti etmediğini göstermektedir.

Genel olarak bulgular, çözüm öğrenmenin faydalı olabileceğini, ancak faydayı ölçmek için kullanılan yerel sinyalin dikkatle tasarlanması gerektiğini ortaya koymaktadır. Gelecek çalışmalarda, genel performansı koruyacak güncelleme kabul kuralları geliştirilebilir. Ayrıca daha fazla veri seti ve farklı çözüm yaklaşımları ile eğitim yapılabilir. Yalnızca sayısal cevaba değil, çözümün tamamına odaklanan değerlendirme metrikleri kullanılabilir.

Kaynaklar

- [1] I. Mirzadeh, K. Alizadeh, H. Shahrokhi, O. Tuzel, S. Bengio ve M. Farajtabar, "GSM-Symbolic: Understanding the Limitations of Mathematical Reasoning in Large Language Models," arXiv:2410.05229,

2024. [Çevrimiçi]. Erişim: <https://arxiv.org/abs/2410.05229>

- [2] A. Didolkar, A. Goyal, N. R. Ke, S. Guo, M. Valko, T. Lillicrap, D. Rezende, Y. Bengio, M. Mozer ve S. Arora, "Metacognitive Capabilities of LLMs: An Exploration in Mathematical Problem Solving," *Advances in Neural Information Processing Systems*, cilt 37, ss. 19783–19812, 2024, doi: 10.52202/079017-0623. [Çevrimiçi]. Erişim: https://proceedings.neurips.cc/paper_files/paper/2024/file/2318d75a06437eaa257737a5cf3ab83c-Paper-Conference.pdf
- [3] R. Wang, R. Wang, Y. Shen, C. Wu, Q. Zhou ve R. Chandra, "Evaluation of LLMs for mathematical problem solving," arXiv:2506.00309, 2025. [Çevrimiçi]. Erişim: <https://arxiv.org/abs/2506.00309>
- [4] K. Cobbe, V. Kosaraju, M. Bavarian, M. Chen, H. Jun, L. Kaiser, M. Plappert, J. Tworek, J. Hilton, R. Nakano, C. Hesse ve J. Schulman, "Training Verifiers to Solve Math Word Problems," arXiv:2110.14168, 2021. [Çevrimiçi]. Erişim: <https://arxiv.org/abs/2110.14168>
- [5] H. Nie, "Fine-Tuning Large Language Models for Solving Math Word Problems: A Case Study with LLaMA-3," *2024 4th International Signal Processing, Communications and Engineering Management Conference (ISPCEM)*, Montreal, QC, Canada, 2024, ss. 100–104, doi: 10.1109/ISPCEM64498.2024.00024.
- [6] Z. Hu, L. Wang, Y. Lan, W. Xu, E.-P. Lim, L. Bing, X. Xu, S. Poria ve R. Lee, "LLM-Adapters: An Adapter Family for Parameter-Efficient Fine-Tuning of Large Language Models," *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*, Singapore, 2023, ss. 5254–5276, doi: 10.18653/v1/2023.emnlp-main.319. [Çevrimiçi]. Erişim: <https://aclanthology.org/2023.emnlp-main.319/>
- [7] E. J. Hu, Y. Shen, P. Wallis, Z. Allen-Zhu, Y. Li, S. Wang, L. Wang ve W. Chen, "LoRA: Low-Rank Adaptation of Large Language Models," arXiv:2106.09685, 2021. [Çevrimiçi]. Erişim: <https://arxiv.org/abs/2106.09685>
- [8] J. Kirkpatrick, R. Pascanu, N. Rabinowitz, J. Veness, G. Desjardins, A. Rusu, K. Milan, J. Quan, T. Ramalho, A. Grabska-Barwinska, D. Hassabis, C. Clopath, D. Kumaran ve R. Hadsell, "Overcoming catastrophic forgetting in neural networks," *Proceedings of the National Academy of Sciences*, 2017. [Çevrimiçi]. Erişim: <https://www.pnas.org/doi/10.1073/pnas.1611835114>
- [9] F. Zenke, B. Poole ve S. Ganguli, "Continual Learning Through Synaptic Intelligence," arXiv:1703.04200, 2017. [Çevrimiçi]. Erişim: <https://arxiv.org/abs/1703.04200>

- [10] Yildiz Technical University Computer Engineering Department Cosmos Research Group, “ytu-ce-cosmos/gsm8k_tr,” Hugging Face Datasets. [Çevrimiçi]. Erişim: https://huggingface.co/datasets/ytu-ce-cosmos/gsm8k_tr
- [11] Qwen Team, “Qwen/Qwen3.5-4B,” Hugging Face Model Card. [Çevrimiçi]. Erişim: <https://huggingface.co/Qwen/Qwen3.5-4B>

Ek Açıklama: Nitel Örnekler

Bu bölümde, benzer soru değerlendirmesinde gözlenen iki örnek verilmiştir. İlk örnek Selective stratejinin doğru kabul ettiği bir yerel aktarım durumunu, ikinci örnek ise Selective ve Blind stratejilerinin birlikte başarısız olduğu bir durumu göstermektedir.

Başarılı Selective Örneği

Bu örnekte M1, orijinal soruda “kalan oylar” ifadesini dikkate almadan James’in oyunu toplam oy üzerinden hesaplamış ve yanlış sonuca ulaşmıştır. Öğretmen çözümüyle yapılan Selective güncellemesinden sonra aynı matematiksel yapıya sahip benzer soruda model doğru çözüm üretmiştir.

Orijinal soru. 3 kişi başkanlık için yarışıyor. John 150 oy almayı başarır. James kalan oyların %70’ini alır. Eğer oy kullanan 1150 kişi varsa, üçüncü kişi John’dan kaç oy daha fazla almıştır?

M1’in orijinal sorudaki çözümü.

1. James’in aldığı oy sayısı: $1150 \times 0.70 = 805$.
2. James’in aldığı oydan kalan üçüncü kişinin aldığı oy sayısı: $1150 - 805 = 345$.
3. John ve üçüncü kişi arasındaki fark: $345 - 150 = 195$.

Final cevap: 195

Öğretmen modelin orijinal sorudaki çözümü.

1. Toplam oy = 1150
2. John = 150 oy
3. Kalan oy = $1150 - 150 = 1000$
4. James = $70 \times 1000 = 700$ oy
5. Üçüncü aday = $1150 - 150 - 700 = 300$ oy
6. Fark = $300 - 150 = 150$

Final cevap: 150

Benzer soru. Üç kişi belediye başkanı seçimi için yarışıyor. Ayşe 120 oy alıyor. Mehmet, kalan oyların %60’ını alıyor. Eğer oy kullanan toplam 980 kişi varsa, üçüncü aday Ahmet’in Ayşe’den kaç oy daha fazla almıştır?

Öğretmen modelin benzer sorudaki çözümü.

1. Toplam oy = 980
2. Ayşe = 120 oy
3. Kalan oy = $980 - 120 = 860$
4. Mehmet = $60 \times 860 = 516$ oy
5. Ahmet = $980 - 120 - 516 = 344$ oy
6. Fark = $344 - 120 = 224$

Final cevap: 224

Selective adapter’ın benzer sorudaki çözümü.

1. Toplam oy = 980
2. Ayşe = 120 oy
3. Kalan oy = $980 - 120 = 860$
4. Mehmet = $60 \times 860 = 516$ oy
5. Ahmet = $980 - 120 - 516 = 344$ oy
6. Fark = $344 - 120 = 224$

Final cevap: 224

Benzer sorunun referans cevabı 224 olduğu için bu güncelleme Selective strateji tarafından kabul edilmiştir.

Her İki Stratejinin Başarısız Olduğu Örnek

Bu örnek oran ve toplam ilişkisi içeren bir problemdir. İki strateji de Mert dışındaki kişilerin toplamını bulmuş, fakat sorunun istediği üç kişinin toplamını hesaplamadan ara sonucu final cevap olarak üretmiştir.

Orijinal soru. Alexis, Dilan ve Ashley’nin toplamından dört kat daha fazla mangoya sahiptir. Alexis’in 60 mangosu varsa, hepsinin toplam kaç mangosu vardır?

M1’in orijinal sorudaki çözümü.

Alexis’in 60 mangosu olduğu verildiğine göre, Alexis’ten dört kat daha fazla olan toplam mangoları bulmak için 60’u 4 ile çarpalım: $60 \times 4 = 240$.

Bu 240 mangonun Alexis’e ait olan 60’u çıkarıldığında, Alexis dışındaki iki kişinin toplam mangosu bulunur: $240 - 60 = 180$.

Son olarak, Alexis’in mangosu 60 ile diğerlerinin toplamı 180 toplanarak hepsinin toplamı elde edilir: $60 + 180 = 240$.

Final cevap: 240

Öğretmen modelin orijinal sorudaki çözümü.

1. Dilan + Ashley = Alexis / 4 = 60 / 4 = 15
2. Toplam = Alexis + Dilan + Ashley = 60 + 15 = 75

Final cevap: 75

Benzer soru. Mert, Selin ve Burak'ın toplamının dört katı kadar kitabı vardır. Mert'in 80 kitabı varsa, üçünün toplam kaç kitabı vardır?

Öğretmen modelin benzer sorudaki çözümü.

1. Selin + Burak = Mert / 4 = 80 / 4 = 20
2. Toplam = Mert + Selin + Burak = 80 + 20 = 100

Final cevap: 100

Selective adapter'ın benzer sorudaki çözümü.

1. $M = 4 \times (S + B)$ ve $80 = 4 \times (S + B)$
2. $S + B = 80 / 4 = 20$

Final cevap: 20

Blind adapter'ın benzer sorudaki çözümü.

1. Mert / 4 = Toplam
2. $80 / 4 = 20$

Final cevap: 20

Benzer sorunun referans cevabı 100'dür. Bu nedenle Selective strateji bu güncellemeyi kabul etmemiş, Blind strateji ise güncellemeyi tutmasına rağmen benzer soruda doğru cevaba ulaşamamıştır.